

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

ANDRÉ LUIS QUIOSI

**CARACTERIZAÇÃO E ANÁLISE DE SÉRIES TEMPORAIS A PARTIR DE
WAVELETS PARA PREDIÇÃO DE PRECIPITAÇÃO**

TOLEDO

2023

ANDRÉ LUIS QUIOSI

**CARACTERIZAÇÃO E ANÁLISE DE SÉRIES TEMPORAIS A PARTIR DE
WAVELETS PARA PREDIÇÃO DE PRECIPITAÇÃO**

**Characterization and analysis of time series using wavelets for precipitation
prediction**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Tecnólogo em Tecnologia em Sistemas
para Internet do Curso Superior de Tecnologia
em Sistemas para Internet da Universidade
Tecnológica Federal do Paraná.

Orientador: Prof. Dr. Fabio Alexandre Spanhol

Coorientador: Prof. Dr. Márcio Paulo de Oliveira

TOLEDO

2023



[4.0 Internacional](https://creativecommons.org/licenses/by/4.0/)

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

ANDRÉ LUIS QUIOSI

**CARACTERIZAÇÃO E ANÁLISE DE SÉRIES TEMPORAIS A PARTIR DE
WAVELETS PARA PREDIÇÃO DE PRECIPITAÇÃO**

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Tecnólogo em Tecnologia em Sistemas
para Internet do Curso Superior de Tecnologia
em Sistemas para Internet da Universidade
Tecnológica Federal do Paraná.

Data de aprovação: 20/novembro/2023

Fabio Alexandre Spanhol
Doutor
Universidade Tecnológica Federal do Paraná

Márcio Paulo de Oliveira
Doutor
Universidade Tecnológica Federal do Paraná

Ivan Luiz Salvadori
Doutor
Universidade Tecnológica Federal do Paraná

**TOLEDO
2023**

Dedico este trabalho à minha família, em especial mãe e irmã pelos momentos de ausência, apoio e compreensão.

AGRADECIMENTOS

Agradeço ao meu orientador Prof. Dr. Fabio Alexandre Spanhol, pela grande sabedoria e paciência, também o coorientador Prof. Dr. Márcio Paulo de Oliveira, que me auxiliou muito nesta trajetória.

Agradecimento também ao meu antigo orientador, que mudou de instituição, Prof. Dr. Thiago Henrique Pereira Silva que me inspirou muito com seu vasto conhecimento no começo dessa jornada.

Aos meus colegas de sala, pelos vários trabalhos realizados em conjunto e experiência compartilhada.

Também aos meus amigos e colegas de graduação, Eduardo, Diego, Paula, Lucas, Gustavo, Cristian e Vinícius que sempre estiveram presentes e ajudando com suas experiências.

Por último, mas não menos importante, imensa gratidão a todos os professores da graduação, por todo conhecimento passado, experiências de vida compartilhadas e paciência em nossas dificuldades.

RESUMO

Nos últimos anos, tem-se evidenciado um acentuado aumento na intensidade das mudanças climáticas, ressaltando a importância crucial da previsão e compreensão dos fenômenos naturais. A análise de dados de séries temporais provenientes de modelos de previsão desempenha um papel fundamental em diversas áreas científicas, abrangendo disciplinas como estatística, meteorologia, agricultura, economia e ciência de dados. A transformada *wavelet* é uma ferramenta matemática amplamente usada na análise desses dados. Ao possibilitar a decomposição das séries em distintas escalas e frequências, esta técnica revela padrões e comportamentos ocultos. Assim, torna-se possível extrair informações significativas, como tendências, sazonalidades, variações de curto prazo e anomalias. A integração da análise de séries temporais com dados espaciais oferece a oportunidade de obter *insights* valiosos sobre a distribuição espacial de fenômenos, identificar padrões geográficos e compreender as interações entre variáveis espaciais e temporais. O presente trabalho propõe compreender os dados de precipitação pluviométrica, considerando suas características espaciais e temporais, para obter conhecimentos sobre os padrões de precipitação, contribuindo assim para uma melhor compreensão dos fenômenos relacionados e auxiliando na tomada de decisões embasadas em informações confiáveis. Como resultado, as representações visuais detalhadas das séries temporais, utilizando a transformada *wavelet*, facilitaram uma compreensão mais aprofundada de seus padrões e mudanças, permitindo a extração de conclusões a partir das evidências apresentadas.

Palavras-chave: transformada wavelet; séries temporais; previsão de precipitação; periodograma; mudança climática.

ABSTRACT

In recent years, there has been a pronounced increase in the intensity of climate change, underscoring the crucial importance of forecasting and understanding natural phenomena. The analysis of time series data from predictive models plays a fundamental role in various scientific areas, encompassing disciplines such as statistics, meteorology, agriculture, economics, and data science. The wavelet transform is a widely used mathematical tool in the analysis of this data. By enabling the decomposition of series into different scales and frequencies, this technique reveals hidden patterns and behaviors. Consequently, it becomes possible to extract significant information, such as trends, seasonalities, short-term variations, and anomalies. The integration of time series analysis with spatial data provides an opportunity to gain valuable insights into the spatial distribution of phenomena, identify geographic patterns, and comprehend the interactions between spatial and temporal variables. The present work aims to understand precipitation data, considering both its spatial and temporal characteristics, to acquire knowledge about precipitation patterns. This contributes to a better understanding of related phenomena and aids in making decisions based on reliable information. As a result, detailed visual representations of time series, using the wavelet transform, facilitated a deeper understanding of their patterns and changes, allowing for the extraction of conclusions from the presented evidence.

Keywords: wavelet transform; time series analysis; precipitation forecast; periodogram; climate change.

LISTA DE FIGURAS

Figura 1 – Seções GRIB	20
Figura 2 – Localização do pixel na área de estudo	21
Figura 3 – Sequência das etapas do trabalho	24
Figura 4 – Detalhamento das atividades realizadas	24
Figura 5 – Figura de exemplo da localização espacial dos dados de previsão de precipitação	27
Figura 6 – Exemplo dos dados de previsão de precipitação localizados em coordenadas geográficas correspondentes ao estado do Paraná	28
Figura 12 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2018	35
Figura 13 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2019	35
Figura 14 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2020	36
Figura 15 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2021	36
Figura 16 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2022	37
Figura 17 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2018, obtidos com a <i>wavelet</i> de Morlet	38
Figura 18 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2019, obtidos com a <i>wavelet</i> de Morlet	38
Figura 19 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2020, obtidos com a <i>wavelet</i> de Morlet	39
Figura 20 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (<i>pixel</i> 94) ano 2021, obtidos com a <i>wavelet</i> de Morlet	39

Figura 21 – Periodogramas das séries temporais de previsão de precipitação de-
cendial para Toledo e Cascavel - PR (*pixel* 94) ano 2022, obtidos com a
***wavelet* de Morlet 40**

LISTA DE TABELAS

Tabela 1 – Tabela demonstrativa dos dados encontrados nas Figuras 17 a 21 . . .	41
--	-----------

LISTAGEM DE CÓDIGOS FONTE

Listagem 1 – Exemplo de requisição de dados da API <i>European Centre for Medium-Range Weather Forecasts</i> (ECMWF)	22
Listagem 2 – Cálculo do espectro de potência <i>wavelet</i> de série temporal univariada	25

LISTA DE ABREVIATURAS E SIGLAS

Siglas

API	<i>Application Programming Interface</i>
EAP	Estrutura Analítica de Projeto
ECMWF	<i>European Centre for Medium-Range Weather Forecasts</i>
GRIB	<i>Gridded Binary</i>
LOESS	<i>Locally Estimated Scatterplot Smoothing</i>
MAE	<i>Mean Absolute Errors</i>
NetCDF	<i>Network Common Data Form</i>
ONU	Organização das Nações Unidas
RMSE	<i>Root Mean-square Error</i>
SVM	<i>Support-vector Machine</i>
TIGGE	<i>The Interactive Grand Global Ensemble</i>
UTC	Coordenada de Tempo Universal
WMO	<i>World Meteorological Organization</i>
WWRP	<i>World Weather Research Programme</i>

SUMÁRIO

1	INTRODUÇÃO	12
1.1	Considerações iniciais	12
1.2	Objetivos	13
1.2.1	Objetivo geral	13
1.2.2	Objetivos específicos	13
1.3	Justificativa	13
2	REFERENCIAL TEÓRICO	15
2.1	Séries Temporais	15
2.2	Transformada Wavelet	16
2.3	Dados Geoespaciais	18
3	TRANSFORMADA WAVELET EM SÉRIES TEMPORAIS DE PRECIPITAÇÃO	20
3.1	Materiais	20
3.1.1	Arquivo GRIB	20
3.1.2	<i>Dataset</i>	21
3.1.3	Séries Temporais	22
3.1.4	Extração dos dados utilizando Python	22
3.1.5	Linguagem R	23
3.2	Métodos	23
3.2.1	<i>Scripts</i>	25
4	RESULTADOS	27
5	CONCLUSÃO	42
	REFERÊNCIAS	43

1 INTRODUÇÃO

1.1 Considerações iniciais

Este trabalho aborda o tema da análise de previsões de precipitação, usando séries temporais de dados pluviométricos georreferenciados para uma análise espacial. O conhecimento relacionado às previsões de precipitação pluviométricas influenciam na tomada de decisões em diversas atividades sociais, econômicas, gestão de recursos hídricos, planejamento urbano e agricultura.

Um dos desafios do trabalho com séries temporais é a seleção adequada de técnicas que possam lidar com a sua complexidade e não linearidade, para isso as *wavelets* têm mostrado eficácia em decompor as séries temporais em diferentes escalas e revelar padrões ocultos.

As *wavelet*, que podem ser traduzidas como “pequenas ondas” tiveram sua primeira aparição na literatura de geofísica, no trabalho de (MORLET *et al.*, 1982). Contudo as *wavelets* foram também desenvolvidas em várias outras áreas da ciência, como estatística, processamento de imagens e hidrologia (BOLZAN, 2006; NORDEMANN, 1998; VETTERLI; HERLEY, 1992).

As bases de dados, de onde foram extraídos os objetos da pesquisa, fazem parte do *World Weather Research Programme* (WWRP), sendo uma iniciativa internacional de pesquisa patrocinada pela *World Meteorological Organization* (WMO). Seu objetivo é impulsionar avanços nas previsões meteorológicas de curto prazo, abrangendo um período de um a quinze dias, especialmente em eventos de grande impacto. Um dos principais componentes do programa é o *The Interactive Grand Global Ensemble* (TIGGE), que desempenha um papel fundamental nesse avanço.

O Centro Europeu de Previsões Meteorológicas a Médio Prazo ECMWF disponibiliza o acesso ao modelo TIGGE, que por sua vez disponibiliza os dados de precipitação pluviométrica, sendo um parâmetro temporal climático altamente variável e de características sazonais. Para tal, foi realizado o tratamento, visualização e criação de mapas temáticos. Além disso, caracterizou-se os dados obtidos por meio de gráficos, proporcionando uma visualização clara da interpretação dos resultados. Também realizou-se a incorporação de dados espaciais georreferenciados, permitindo uma análise abrangente e contextualizada no espaço. A expectativa para este trabalho é os resultados contribuírem para um melhor entendimento das séries temporais de previsão de precipitação de alcance decenal do modelo ECMWF com o uso de *wavelets* na localização interna da mesorregião oeste do estado do Paraná.

1.2 Objetivos

1.2.1 Objetivo geral

Analisar séries temporais não estacionárias de previsão de chuvas, aplicando a transformada *wavelet*, com vistas a contribuir para um melhor entendimento das informações contidas no método, informações essas que podem ser utilizadas no planejamento de diversas atividades. Com isso, melhorar as tomadas de decisões em relação a eventos climáticos extremos, impactando positivamente na qualidade de vida da população.

1.2.2 Objetivos específicos

Cumprir as seguintes etapas metodológicas relacionadas ao escopo deste estudo. Realizar a aquisição de dados meteorológicos de fontes oficiais como o ECMWF¹. Tratar e limpar os dados coletados, assegurando que a qualidade dos mesmos seja adequada para análises subsequentes. Representar as séries temporais através da aplicação de transformadas de wavelets, que permitem a decomposição dos dados em componentes de frequência-tempo para uma análise mais refinada. Realizar a visualização e interpretação dos dados por meio de tabelas, gráficos e mapas temáticos, facilitando a compreensão e a identificação de padrões ou tendências significativas nos fenômenos meteorológicos investigados.

1.3 Justificativa

De acordo com a Organização das Nações Unidas (ONU)², as mudanças climáticas, sendo elas naturais, tal qual as variações no ciclo solar, ou atividades humanas, como a queima de combustíveis fósseis, refletem transformações ao longo do tempo nos padrões de temperatura e clima. Tais mudanças percebidas e analisadas nas últimas décadas trouxeram uma problemática para diversas atividades humanas, como a agricultura, transporte de mercadorias, transporte humano, viagens, entre outras. Essas transformações tornaram mais desafiadora a tarefa de analisar dados climáticos para prever fenômenos naturais. As ferramentas e métodos que foram empregados por um longo período agora demonstram menor eficácia (MALHI; KAUR; KAUSHIK, 2021).

Tomando como base de estudo a região oeste do estado do Paraná, temos como peça fundamental o agronegócio, que movimenta a economia regional³ e contém grandes cooperativas que exportam suas produções. (ALMEIDA, 2020) Além disso, outro ponto de interesse é

¹ <https://www.ecmwf.int/>

² <https://shorturl.at/hrERV>, acessado em 02/05/2023.

³ Agência Estadual de Notícias: <https://shorturl.at/abkFM>, acessado em 28/05/2023.

o rio Paraná e seus afluentes, que cobre toda a divisa oeste do estado do Paraná, fornecendo água e a capacidade de produção de energia elétrica na usina hidrelétrica de Itaipu.

Este trabalho contribui para a interdisciplinaridade dos aspectos socioeconômicos, desastres naturais, análises matemáticas resolvidas por métodos avançados de programação dinâmica (transformada de *wavelet*), engenharia hídrica, pesquisa geofísica, pesquisa ambiental, agronomia, entre outros.

2 REFERENCIAL TEÓRICO

2.1 Séries Temporais

Séries temporais referem-se a conjuntos de dados coletados, registrados ou observados em intervalos regulares ao longo do tempo, organizados cronologicamente para analisar padrões, tendências e variações. Amplamente aplicadas em setores como finanças, economia, meteorologia, ciência ambiental e engenharia, essas séries proporcionam percepções cruciais. Conceitos essenciais associados incluem observações temporais, vinculando cada ponto de dados a um momento específico, tendências que representam mudanças de longo prazo (ascendentes, descendentes ou constantes), padrões sazonais refletindo variações periódicas, flutuações aleatórias como variações não sistemáticas e ciclos representando padrões recorrentes de aumento e diminuição sem duração fixa. Essa análise é fundamental para prever comportamentos futuros, sendo aplicada estrategicamente em diversas áreas (MORETTIN; TOLOI, 2018).

A teoria de Fourier, desenvolvida por Joseph Fourier antes de 1930, é fundamental para a compreensão da análise de frequência de funções periódicas. Fourier postulou que qualquer função periódica $f(x)$ pode ser representada como a soma infinita de senos e cossenos, conforme expresso na Equação 1.

$$f(x) = a_0 + \sum_{k=1}^{\infty} (a_k \cos(kx) + b_k \sin(kx)) \quad (1)$$

Essa formulação significa que a função periódica pode ser decomposta em componentes fundamentais senoidais. Os coeficientes a_0 , a_k e b_k são determinados pelas integrais definidas de $f(x)$, como indicado nas Equações 2, 3 e 4.

$$a_0 = \frac{2}{\pi} \int_0^{2\pi} f(x) dx \quad (2)$$

$$a_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \cos(kx) dx \quad (3)$$

$$b_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \sin(kx) dx \quad (4)$$

Essas fórmulas permitem calcular os coeficientes que descrevem a contribuição de cada termo senoidal na representação da função periódica. Assim, essa abordagem permite decompor funções periódicas complexas em componentes mais simples, facilitando a compreensão e manipulação dessas funções em contextos analíticos e computacionais (BOLZAN, 2004).

No entanto, a abordagem de Fourier tem limitações quando se trata de representar funções não periódicas ou funções com descontinuidades. É nesse contexto que a transformada de

wavelet (ou transformada em ondeletas) se destaca, oferecendo uma abordagem mais flexível e adaptável para analisar sinais em diferentes escalas de frequência e localizações no tempo.

2.2 Transformada Wavelet

Existem diferentes transformadas, entre as mais utilizadas e conhecidas temos o grupo de Wavelet Haar, sendo as *wavelets* mais simples e foram as primeiras a serem introduzidas na teoria das *wavelets*, tendo um tamanho fixo e são usadas para a decomposição de sinais discretos (LEPIK; HEIN, 2014); Wavelet Daubechies, são um conjunto de *wavelets* ortogonais que possuem um número finito de coeficientes, essas *wavelets* são amplamente utilizadas na compressão de imagens e em outras aplicações de processamento de sinais (LINA; MAYRAND, 1995); Wavelet Coiflet, que possuem um bom desempenho em aplicações que envolvem a detecção de bordas em imagens (WEI, 1998) e Wavelet de Morlet, que são moduladas por uma função senoidal. Elas são usadas em aplicações que envolvem a análise de sinais não-estacionários (MORLET *et al.*, 1982).

Dessa forma, neste estudo, pressupomos que a análise dos dados de previsão de séries temporais não estacionárias seria realizada por meio da aplicação da transformada *wavelet* de Morlet. De forma aprofundada, essas transformadas são funções matemáticas importantes na análise de sinais e processamento de dados, pois permitem decompor um sinal em diferentes frequências ou resoluções, revelando informações sobre sua estrutura e comportamento em diferentes escalas. À medida que a resolução aumenta, detalhes mais finos tornam-se visíveis (BOLZAN, 2004). Este processo de decomposição ocorre da seguinte maneira.

Iniciamos considerando uma função f pertencente ao espaço de funções quadraticamente integráveis $L_2(\mathbb{R})$. Portanto, a energia da função f é limitada ao longo do eixo real, conforme a equação:

$$\int_{-\infty}^{+\infty} |f(t)|^2 dt < \infty \quad (5)$$

O produto escalar, representado por (\bullet) , e a norma para o espaço $L_2(\mathbb{R})$ são definidos como:

$$f \bullet g = \int_{-\infty}^{+\infty} f(t) \cdot g(t) dt \quad (6)$$

$$|f| = \sqrt{f \bullet f} \quad (7)$$

Se a função g tiver uma norma unitária, então o produto escalar entre f e g corresponderá à operação de projeção de f sobre g .

Agora, considere um conjunto de funções ortonormais $\Psi_k(t)$, $k \in \mathbb{N}$, ou seja, ortogonais e de módulo 1, formando uma base para o espaço $L_2(\mathbb{R})$. Pela condição de ortogonalidade:

$$\Psi_m \bullet \Psi_n = 0 \quad (8)$$

para todo m diferente de n . A expansão da função f em uma série ortonormal é então definida como a combinação linear das funções base ponderadas pelas projeções de f sobre cada uma delas:

$$f(t) = \sum_{k=-\infty}^{\infty} \langle f, \Psi_k \rangle \Psi_k(t) \quad (9)$$

Isso pode ser expresso como:

$$f(t) = \sum_{k=-\infty}^{\infty} F_k \Psi_k(t) \quad (10)$$

onde F_k representa a transformada da função $f(t)$. Imbuído nessa abordagem está o fato de a base $\Psi_k(t)$ ter suporte em toda a extensão do eixo real, ou seja, cada função base $\Psi_k(t)$ decai para zero apenas nos limites de $\pm\infty$. No entanto, se a base tiver suporte limitado, decaindo para zero muito rapidamente, a melhor maneira de cobrir todo o eixo real com essa base seria por meio de translações do tipo:

$$\Psi_{k,l}(t) = \Psi_k(t - l), l \in \mathbb{N} \quad (11)$$

Assim, o termo “ondeleta” refere-se a um conjunto de funções com a forma de pequenas ondas geradas por dilatações, onde $\Psi(t) \rightarrow \Psi(2t)$, e translações, onde $\Psi(t) \rightarrow \Psi(t + 1)$, de uma função base geradora simples $\Psi(t)$, chamada de ondeleta-mãe. Esta ondeleta-mãe deve ser quadraticamente integrável dentro de um intervalo de tempo real ou espaço $[L_2(\mathbb{R})]$, ou seja, deve apresentar energia finita. A condição de admissibilidade da função é imposta pela exigência de que sua energia média seja zero. Isso é expresso pela seguinte equação:

$$\Psi_{a,b}(t) = \frac{1}{\sqrt{2}} \Psi\left(\frac{t-b}{a}\right) \quad (12)$$

Assim, a expansão em série de ondeletas e a transformada são definidas como:

$$\langle f, \Psi_{a,b} \rangle = \int_{-\infty}^{+\infty} \Psi\left(\frac{t-b}{a}\right) dt. \quad (13)$$

Por exemplo, Santos e Moraes (2013) aplicaram a transformada de Morlet (MORLET *et al.*, 1982) para o cenário de previsão de precipitação e analisaram a pluviometria com espectro

global de potências *wavelets* para análise hídrica da bacia do São Francisco. Com base na metodologia aplicada e nos resultados obtidos, os autores concluíram que a transformada wavelet é uma ferramenta eficaz para a regionalização hidrológica da bacia do rio São Francisco. Revelam também que a aplicação dessa abordagem mostrou-se promissora ao identificar padrões espaciais e temporais na distribuição dos recursos hídricos, e os resultados obtidos fornecem informações valiosas para o planejamento e a gestão dos recursos hídricos na região.

Já no trabalho de Santos e Freire (2012) a transformada foi utilizada para analisar e prever as chuvas para a região Nordeste do país, com o intuito de prevenção de eventos de inundação em grandes cidades nordestinas. Como conclusão os autores chegaram a uma análise detalhada dos espectros de potencia *wavelet* e com isso puderam separar algumas grandes cidades nordestinas em grupos com padrões semelhantes de precipitação, sendo Maceió e Salvador possuindo padrões pluviométricos semelhantes e Aracaju também se aproxima dos padrões das cidades anteriores. Por outro lado, João Pessoa, Natal e Recife formam um grupo distinto e Fortaleza, Teresina e São Luís exibem características únicas, o que impede sua inclusão ou formação de outro grupo.

Também, outros trabalhos tornam a predição de eventos climáticos mais robustos combinando diversas técnicas (WU *et al.*, 2021; CHIDEPUDI *et al.*, 2023; YEDITHA *et al.*, 2023). Por exemplo, Kisi e Cimen (2012) propuseram uma nova estratégia combinando *wavelets* com algoritmos de aprendizado de máquina para previsões de precipitação. Especificamente, eles combinaram uma transformação discreta de *wavelets* com máquina de vetores de suporte *Support-vector Machine* (SVM). Focando em uma região bem específica da Turquia, eles avaliaram a proposta em termos das métricas da raiz do erro quadrático médio *Root Mean-square Error* (RMSE), erro médio absoluto *Mean Absolute Errors* (MAE) e coeficiente de correlação. Como resultado, a proposta gera a previsão de chuva para o dia seguinte.

2.3 Dados Geoespaciais

Dados geoespaciais, também conhecidos como “geodados”, representam informações que estão diretamente relacionadas a pontos ou regiões na superfície terrestre, permitindo a representação cartográfica de objetos e eventos em áreas geográficas específicas, identificadas por meio de coordenadas de latitude e longitude. A visualização geoespacial frequentemente se vale de tecnologia geoespacial para criar mapas interativos e representações gráficas tridimensionais. Essa prática desempenha um papel fundamental na obtenção de uma compreensão mais profunda dos padrões e tendências que ocorrem na superfície terrestre, contribuindo significativamente para o acúmulo de conhecimento sobre o impacto ambiental nas vidas das pessoas e na natureza (LOPES; DELBEM; SOUSA, 2021).

A utilização de geodados e ferramentas de geolocalização tem se tornado cada vez mais crucial nas áreas de planejamento urbano, gestão de recursos naturais, prevenção de desastres, navegação, monitoramento ambiental, e muitas outras. Essas informações espaciais permitem

não apenas a representação de dados geográficos de forma eficaz, mas também auxiliam na tomada de decisões informadas e na criação de políticas públicas mais eficazes.

Graças aos avanços tecnológicos na aquisição e análise de geodados, é possível realizar análises mais detalhadas e precisas, permitindo o acompanhamento de mudanças ao longo do tempo e a identificação de áreas com necessidades especiais de intervenção. Portanto, os geodados desempenham um papel crucial na compreensão do nosso planeta, bem como na preservação e na gestão sustentável dos recursos naturais.

3 TRANSFORMADA WAVELET EM SÉRIES TEMPORAIS DE PRECIPITAÇÃO

3.1 Materiais

3.1.1 Arquivo GRIB

O ECMWF fornece um grande conjunto de dados e uma *Application Programming Interface* (API) que permite desenvolvedores e pesquisadores acessarem e recuperarem de maneira padronizada dados meteorológicos e climáticos dessa instituição. Na meteorologia e ciências climáticas comumente são usados os formatos *Gridded Binary* (GRIB) ou *Network Common Data Form* (NetCDF). Neste trabalho utilizamos dados do modelo TIGGE, disponibilizados pela API no formato GRIB. Esses arquivos contêm informações em forma de grades regulares, onde os dados são organizados em uma estrutura hierárquica.

Figura 1 – Seções GRIB

SECTION 0 - Indicator Section
SECTION 1 - Identification Section
SECTION 2 - [Local Use Section]
SECTION 3 - Grid Definition Section
SECTION 4 - Product Definition Section
SECTION 5 - Data Representation Section
SECTION 6 - Bitmap Section
SECTION 7 - Binary Data Section
SECTION 8 - End Section

Fonte: GRIB decoding Computer User Training Course 2017.

A estrutura básica de um arquivo GRIB consiste em seções lógicas, cada uma com uma finalidade específica. As principais seções demonstradas na Figura 1 incluem:


1. **Seção de Cabeçalho** (*SECTION 0*): Esta seção contém informações gerais sobre o arquivo GRIB, como a versão do formato, tamanho do arquivo, data de criação e informações adicionais.
2. **Seção de Identificação** (*SECTION 1*): Essa seção contém informações sobre o produto ou mensagem contida no arquivo GRIB, como o tipo de dados meteorológicos (por exemplo, temperatura, umidade, vento) e a grade espacial utilizada.
3. **Seção de Grade** (*SECTION 3*): Nesta seção, são especificados os detalhes da grade espacial utilizada para representar os dados. Isso inclui informações sobre a latitude e longitude dos pontos da grade, bem como os intervalos de grade em termos de latitude e longitude.

4. **Seção de Registros de Dados** (*SECTION 7*): Esta é a seção que contém os dados meteorológicos ou oceânicos propriamente ditos. Os valores são armazenados em formato binário e organizados de acordo com a grade espacial especificada na seção anterior.
5. **Seção de Fim de Arquivo** (*SECTION 8*): Esta seção marca o final do arquivo GRIB e contém informações adicionais, como um código de verificação para verificar a integridade dos dados.

3.1.2 Dataset

Neste estudo, foi conduzida uma análise de série temporal para previsão de precipitação pluviométrica usando o modelo ECMWF, com um horizonte de previsão de 240 horas, equivalente a um período de dez dias (decêndio). Na fase inicial, será realizada a estratificação espacial dos dados, selecionando as coordenadas geográficas correspondentes a um retângulo que abrange o estado do Paraná (55°W, 48°W, 27°S, 22°S), conforme mostrado na Figura 2. Os *pixels* têm uma dimensão de $0,5^\circ \times 0,5^\circ$, totalizando 165 *pixels*, onde os valores em cada um deles são obtidos por interpolação realizada com base nos próprios dados disponíveis. A região de estudo selecionada nesse trabalho corresponde ao *pixel* 94 dentro da mesorregião Oeste do Paraná, que abrange as cidades de Toledo e Cascavel.

Figura 2 – Localização do pixel na área de estudo



Fonte: Autoria própria (2023).

3.1.3 Séries Temporais

O próximo passo envolve a estratificação temporal, que requer uma análise detalhada dos dados divididos em decêndios referentes aos anos de 2018, 2019, 2020, 2021 e 2022. Além disso, é crucial levar em consideração a Coordenada de Tempo Universal (UTC) para garantir uma interpretação precisa dos eventos no contexto temporal. Destaca-se que 00:00 UTC corresponde a 03:00 no horário de Brasília (BRT), o que implica uma diferença horária importante a ser ajustada ao analisar e correlacionar os dados ao longo desse período.

3.1.4 Extração dos dados utilizando Python

Para realizar a extração de dados meteorológicos do ECMWF, utilizou-se os parâmetros definidos e armazenados em um arquivo no formato GRIB. A Listagem 1 mostra um trecho de código Python especificando os parâmetros da requisição de dados através da API ECMWF, correspondendo à descrição da Seção 3.1.2.

Listagem 1 – Exemplo de requisição de dados da API ECMWF

```

1 from ecmwfapi import ECMWFDataServer
2 server = ECMWFDataServer()
3 server.retrieve({
4     "class": "ti",
5     "dataset": "tigge",
6     "date": "2018-01-01/to/2018-01-31",
7     "stream": "ENFO",
8     "grid": "0.5/0.5",
9     "levtype": "sfc",
10    "number": "0",
11    "origin": "ecmf",
12    "param": "228",
13    "step": "240",
14    "time": "00:00:00",
15    "type": "cf",
16    "area": "-22/305/-27/312",
17    "target": "ECMWF_Step_240_201801.grib",
18 })

```

Fonte: Autoria própria (2023).

Aqui temos uma breve descrição de cada parâmetro.

- `class`: Define a classe de dados como “ti” (*Temporal Interpolation*).
- `dataset`: Especifica origem do conjunto de dados como “tigge”.
- `date`: Define o intervalo de datas para recuperar os dados, de 1 de janeiro de 2018 a 31 de janeiro de 2018.
- `stream`: Indica o fluxo de dados como “ENFO” (*Ensemble Forecast*).
- `grid`: Especifica a grade de dados como Lat/Lon “0.5/0.5”.

- `levtype`: Tipo de nível, neste caso, “sfc” (*surface*).
- `origin`: Origem dos dados, aqui é “ecmf”.
- `param`: Parâmetro a ser recuperado, neste caso, “228” (*Total Precipitation*).
- `step`: Passo de tempo, aqui é “240” horas.
- `time`: Tempo da previsão, definido como “00:00:00”.
- `type`: Tipo de dados como “cf” (*Forecast*).
- `area`: Área geográfica para a qual os dados são solicitados.

Esses e outros parâmetros estão descritos na documentação do usuário¹ no ECMWF.

3.1.5 Linguagem R

A linguagem R² foi desenvolvida especificamente para análise estatística e visualização de dados. Essa linguagem possui uma ampla variedade de pacotes estatísticos e gráficos, tornando-se uma escolha popular entre estatísticos e pesquisadores, também oferece uma sintaxe especializada para análise estatística. As principais bibliotecas que serão usadas são `rgdal`³, `raster`⁴, `sp`⁵, `maptools`⁶, `rworldmap`⁷, `rgeos`⁸ e `WaveletComp`⁹.

Ambas as linguagens têm suas vantagens e são amplamente adotadas pela comunidade de análise de dados. Python é conhecido por sua versatilidade e popularidade geral, sendo usado tanto em empresas como no meio acadêmico. R, por sua vez, é altamente especializado em estatística e análise de dados, sendo frequentemente utilizado em pesquisas científicas e projetos que requerem análise estatística avançada e gráficos complexos.

3.2 Métodos

O trabalho foi desenvolvido conforme o planejamento de atividades demonstrado na Figura 3. Inicialmente, definiu-se o escopo e objetivos do trabalho. Os objetivos foram tratados em ordem, desde a coleta de dados, seguindo o desenvolvimento em relação ao tratamento de

¹ User Documentation: <https://confluence.ecmwf.int/display/UDOC/Keywords+in+MARS+and+Dissemination+requests>

² The R Project for Statistical Computing: <https://www.r-project.org/>, acessado em 20/05/2023.

³ `rgdal`: <https://cran.r-project.org/package=rgdal>, acessado em 21/05/2023.

⁴ `raster`: <https://cran.r-project.org/package=raster>, acessado em 21/05/2023.

⁵ `sp`: <https://cran.r-project.org/package=sp>, acessado em 21/05/2023.

⁶ `maptools`: <https://cran.r-project.org/package=maptools>, acessado em 21/05/2023.

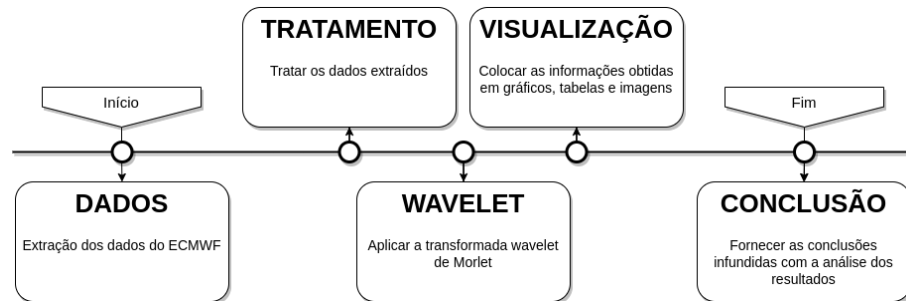
⁷ `rworldmap`: <https://cran.r-project.org/package=rworldmap>, acessado em 21/05/2023.

⁸ `rgeos`: <https://cran.r-project.org/package=rgeos>, acessado em 21/05/2023.

⁹ `WaveletComp`: <https://cran.r-project.org/package=WaveletComp>, acessado em 01/10/2023.

dados e a representação de séries temporais, e, por fim, a visualização de dados. Em paralelo, uma revisão sistemática da literatura ao longo do período letivo, bem como a escrita da redação final do TCC nos últimos quatro meses.

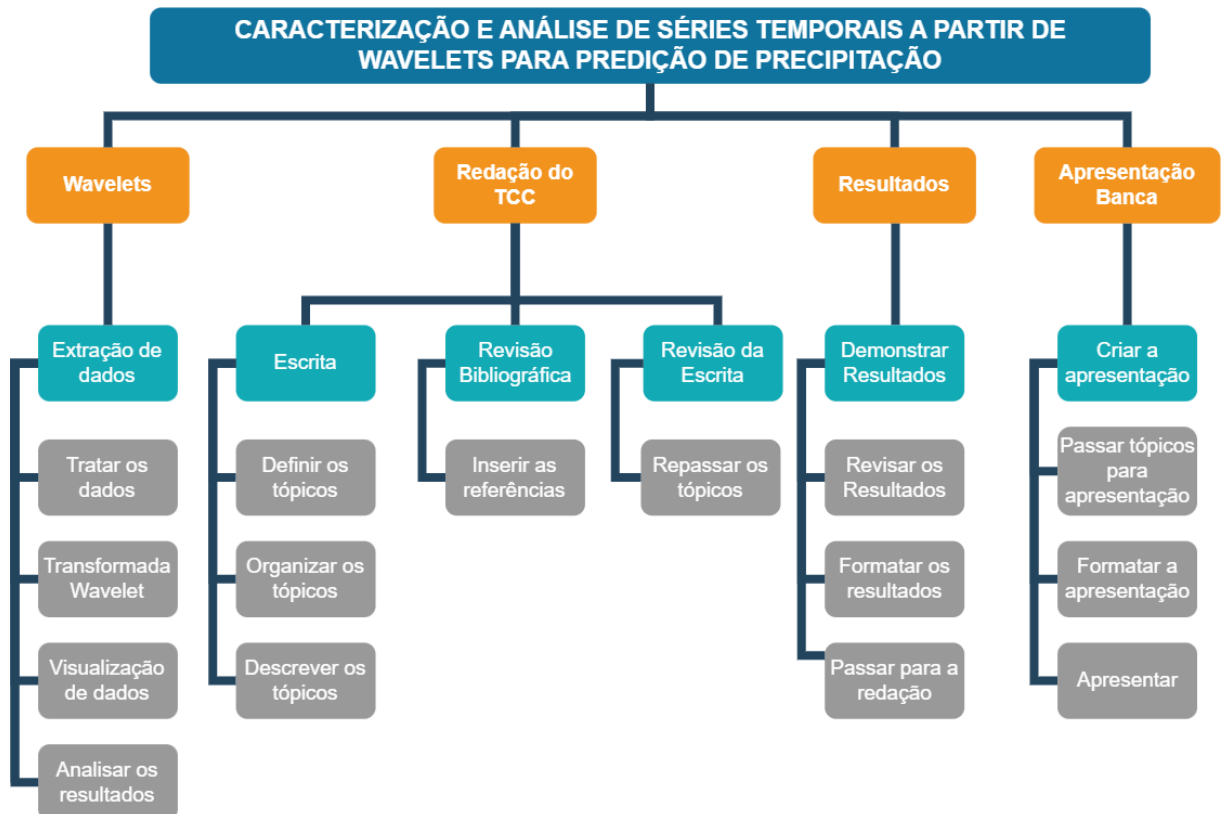
Figura 3 – Sequência das etapas do trabalho



Fonte: Autoria própria (2023).

Para demonstrar de forma mais detalhada todo o trabalho realizado durante a pesquisa e desenvolvimento, foi criado uma Estrutura Analítica de Projeto (EAP), Figura 4, que proporciona uma organização visual dos entregáveis do trabalho em diversos níveis, fundamentando-se nas dependências entre eles. Essencialmente, a EAP representa o plano do projeto em um formato visual, com o objetivo principal no topo e as dependências e sub dependências dispostas hierarquicamente abaixo.

Figura 4 – Detalhamento das atividades realizadas



Fonte: Autoria própria (2023).

3.2.1 Scripts

Os *scripts* desenvolvidos com a linguagem R para realizar as transformadas em ondaleta e gerar seus gráficos, foram baseados no documento desenvolvido por (ROESCH; SCHMIDBAUER, 2018), disponível na documentação da biblioteca WaveletComp. A seguir estão demonstrados os *scripts* juntamente com a descrição de seus parâmetros.

Listagem 2 – Cálculo do espectro de potência *wavelet* de série temporal univariada

```

1  wavelet <- analyze.wavelet (
2    dados,
3    "Precipitacao",
4    loess.span = 0,
5    dt = 1 / 12,
6    dj = 1 / 250,
7    lowerPeriod = 0.150,
8    upperPeriod = 8,
9    make.pval = TRUE,
10   n.sim = 10
11 )

```

Fonte: Autoria própria (2023).

Na Listagem 2, a função `analyze.wavelet()`, pertencente à biblioteca WaveletComp, é empregada para a realização de uma análise *wavelet* de uma série temporal. Os argumentos da função são configurados da seguinte maneira:

- `dados`: Representa a série temporal que será submetida à análise, devendo ser univariada.
- `"Precipitacao"`: Nome da variável dentro do conjunto de dados a ser analisada pela função.
- `loess.span = 0`: Define o grau de suavização *Locally Estimated Scatterplot Smoothing* (LOESS) para atenuar tendências na série temporal, onde o valor 0 indica a ausência de suavização.
- `dt = 1 / 12`: Especifica o intervalo entre as observações na série temporal, sendo 1/12 representativo de observações mensais.
- `dj = 1 / 250`: Determina o passo de frequência na transformada de *wavelet*, onde um valor menor proporciona maior resolução de frequência.
- `lowerPeriod = 0.150`: Menor período a ser considerado na análise, permitindo a detecção de ciclos curtos dentro da série.
- `upperPeriod = 8`: Maior período a ser analisado, possibilitando a identificação de ciclos mais longos.

- `make.pval = TRUE`: Indica se os valores (p-valores¹⁰), para testar a significância estatística, devem ser calculados.
- `n.sim = 10`: Quantidade de simulações que serão realizadas para a estimativa dos p-valores.

O resultado da função `analyze.wavelet()` permitem a análise detalhada da variável "Precipitacao" em diferentes escalas temporais e frequências, bem como a avaliação da significância estatística dos padrões encontrados.

¹⁰ p-valor: No contexto da análise de wavelet, os p-valores são usados para determinar se os coeficientes de wavelet são significativamente diferentes de zero. Se o p-valor for pequeno, isso indica que o coeficiente de wavelet é significativamente diferente de zero, o que sugere que há uma característica significativa na série temporal nesse ponto de tempo e escala.


4 RESULTADOS

Como entrada, o problema recebeu arquivos no formato GRIB, que contêm dados meteorológicos. Em seguida, foram aplicadas as transformadas *wavelets* para extrair características relevantes desses dados, conforme detalhado na Seção 3.2.

A partir dos dados extraídos do arquivo GRIB, pôde-se demonstrar através da Figura 5 um gráfico com coordenadas geoespaciais (55°W, 48°W, 27°S, 22°S) e escala de cores representando a previsão em milímetros, os quadrados com escala de cores e resolução de $0,5^\circ \times 0,5^\circ$, são os *pixels* de cada superfície de previsão de precipitação com alcance de 240h.

Para um melhor entendimento da escala e cores, deve-se levar em consideração a convenção de cores para representar precipitação pluviométrica em mapas meteorológicos, sendo uma prática comum para facilitar a interpretação visual dos dados. Diferentes instituições e organizações podem adotar convenções ligeiramente diferentes, mas geralmente seguem um padrão geral de cores para indicar diferentes níveis de precipitação. Com isso para os dados representado neste trabalho foi usada a escala onde cores mais quentes, como vermelho e amarelo, representam níveis elevados de precipitação e cores mais frias, como azul escuro e claro, representam baixos níveis de precipitação.

Figura 5 – Figura de exemplo da localização espacial dos dados de previsão de precipitação

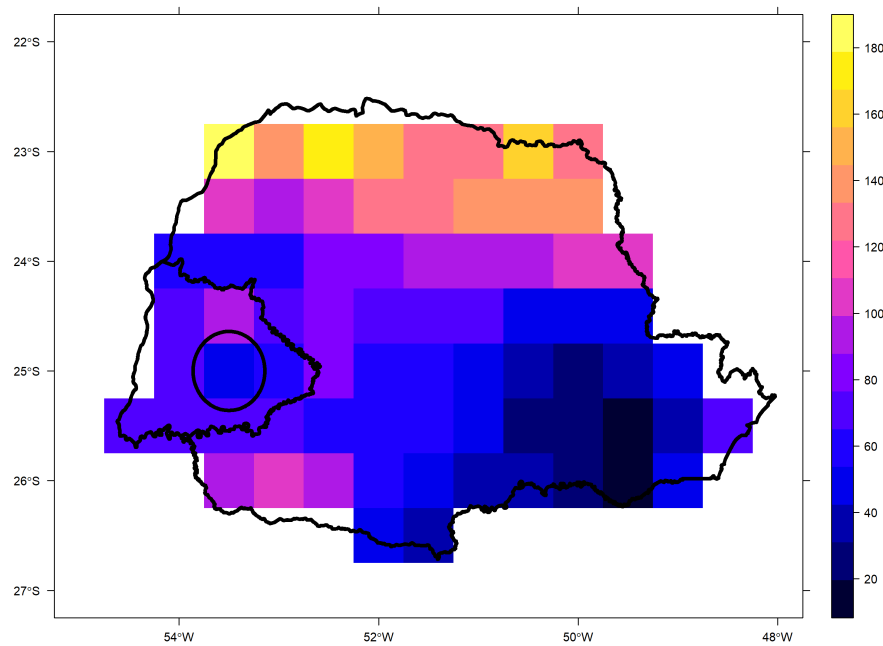


Fonte: Autoria própria (2023).

Como sequência da demonstração dos dados, temos a Figura 6, sendo uma melhora na apresentação dos dados mostrados anteriormente na Figura 5. Aqui temos os dados para o primeiro decêndio de Janeiro de 2018, com a aplicação do recorte para o estado do Paraná, jun-

tamente com a região Oeste destacada, onde se encontram diversas cidades banhadas pelos afluentes do rio Paraná e com grande produtividade agrícola. Por fim, temos um círculo onde se encontra o *pixel* 94 de uma sequência de 165, que se encontram duas das principais cidades do território, sendo elas Toledo e Cascavel, sendo esse *pixel* nossa área de estudo. Pode-se visualizar melhor essas localizações na Figura 2.

Figura 6 – Exemplo dos dados de previsão de precipitação localizados em coordenadas geográficas correspondentes ao estado do Paraná



Fonte: Aatoria própria (2023).

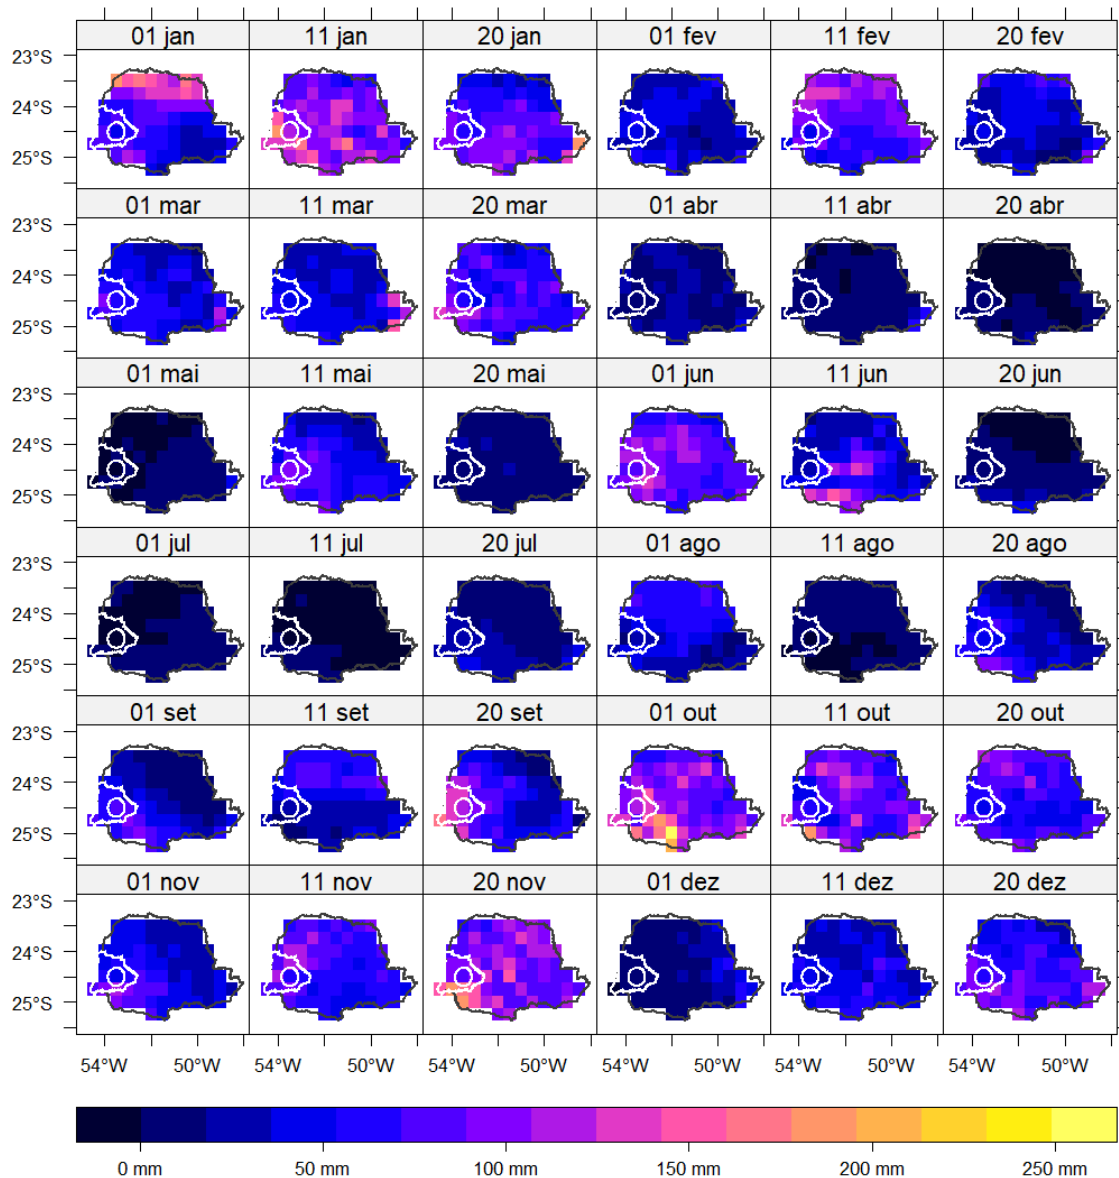
Para os dados das Figuras 7 a 11 temos os anos de 2019 a 2022, sendo cada mês dividido em decêndios, demonstrados pelos vários mapas com o mesmo recorte exemplificado na Figura 6.

As previsões de precipitação pluviométrica para cada uma das datas foram obtidas por meio do modelo do ECMWF, considerando um intervalo de 240 horas, correspondente aos decêndios (dez dias) e ao horário 00:00 UTC. Os valores dos *pixels* exibem variabilidade tanto temporal quanto espacial, destacando-se especialmente aqueles circundados, que compõem a série temporal em análise.

Na área de estudo, é notável uma ampla flutuação na variável de previsão de precipitação pluviométrica, variando de zero durante períodos de estiagem a valores próximos de 250 mm. Essa significativa oscilação denota um padrão não estacionário na série de dados. Os dois extremos nessa série apontam potenciais problemas, pois períodos prolongados de estiagem podem impactar a disponibilidade de água nos municípios, enquanto episódios de precipitações intensas podem ocasionar danos tanto em áreas urbanas quanto rurais.

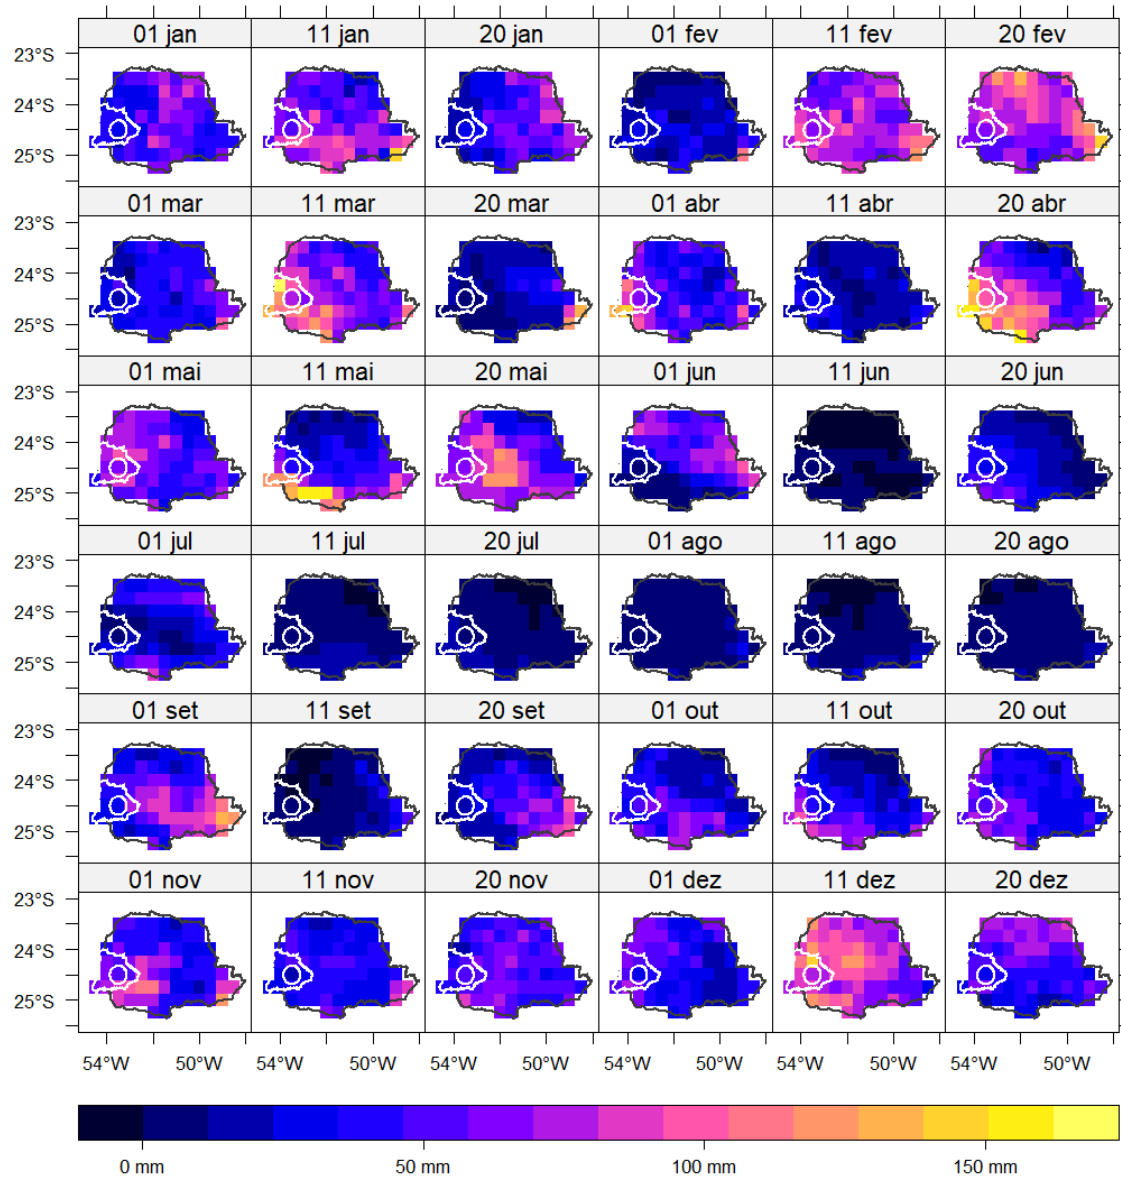
Nas zonas urbanas, chuvas intensas frequentemente resultam em inundações, afetando o tráfego e causando danos às residências, acarretando prejuízos para os moradores. Em regiões rurais, os principais danos estão relacionados às atividades agrícolas, com possíveis impactos negativos nas colheitas, diminuindo a produtividade e, consequentemente, afetando a renda das famílias dependentes dessas atividades.

Figura 7 – Localização espacial dos dados da série temporal. Os círculos indicam os *pixels* em cada superfície de previsão que contém os dados da série temporal para o ano de 2018



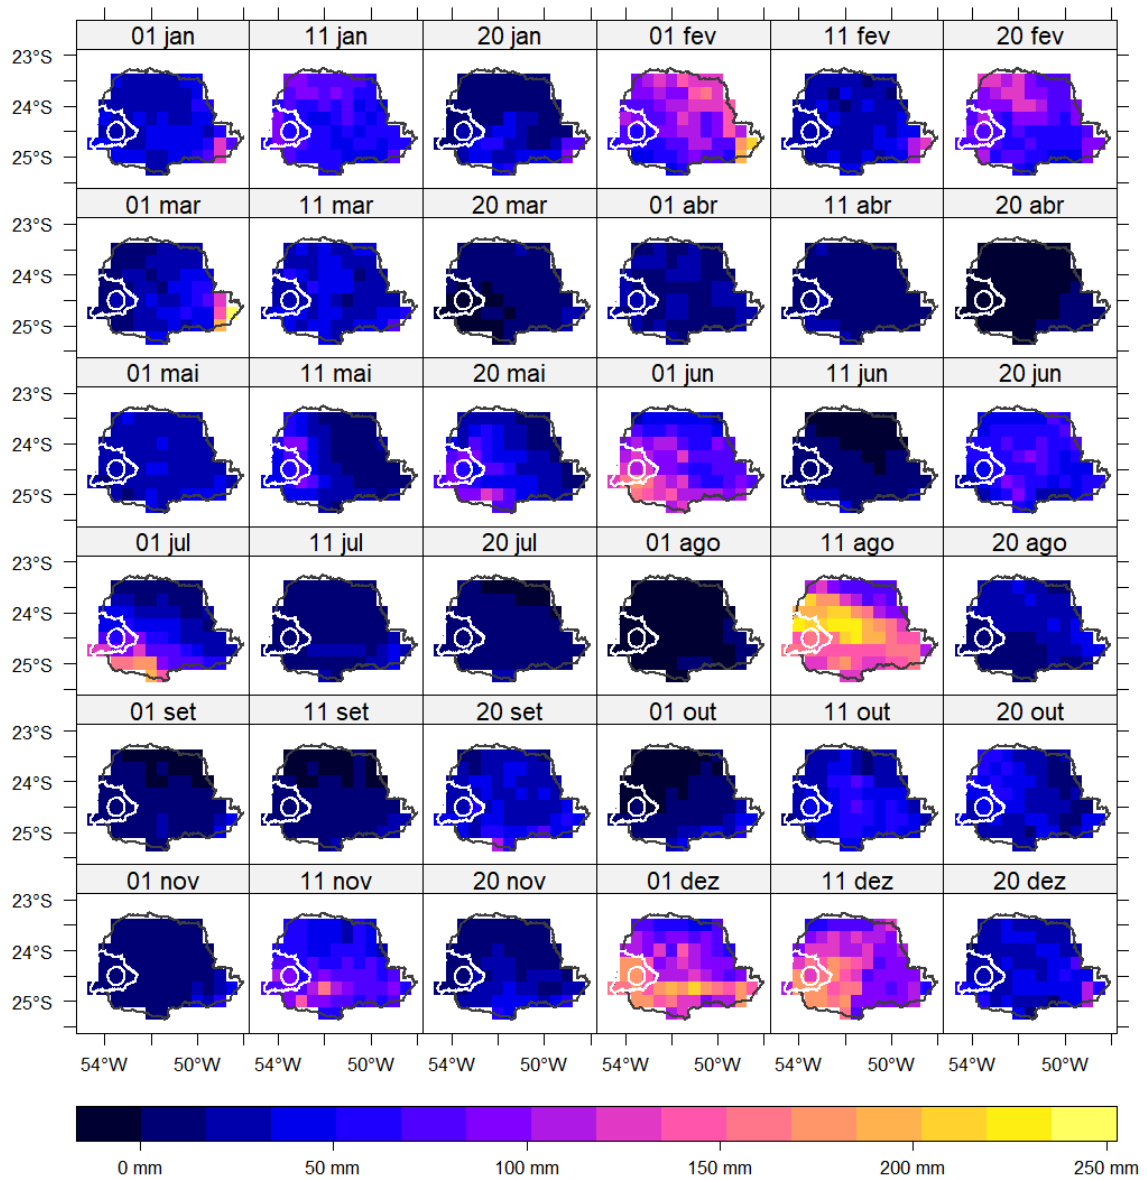
Fonte: Autoria própria (2023).

Figura 8 – Localização espacial dos dados da série temporal. Os círculos indicam os *pixels* em cada superfície de previsão que contém os dados da série temporal para o ano de 2019



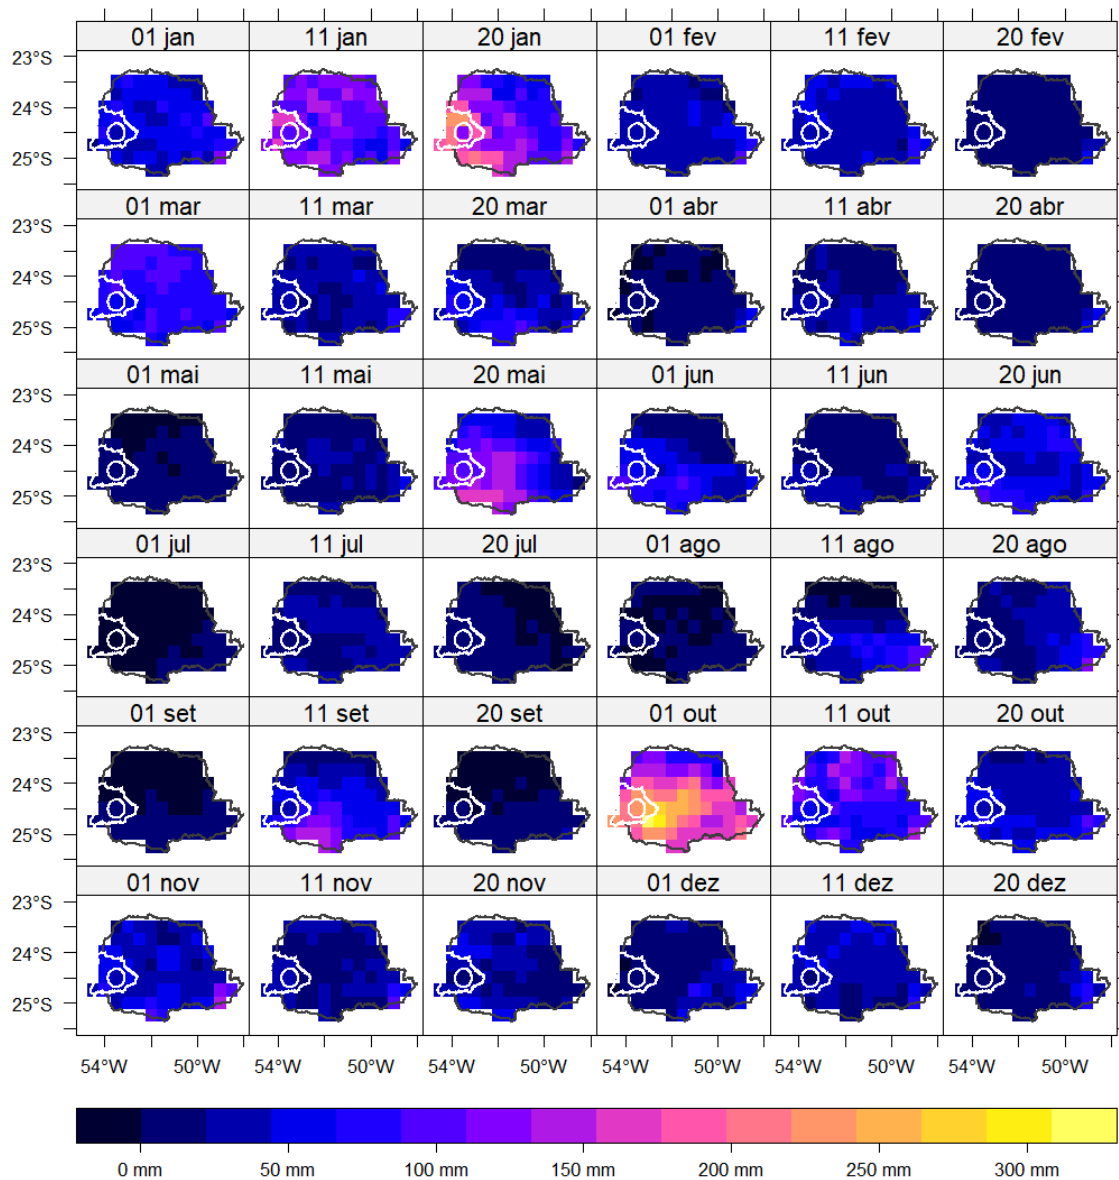
Fonte: Autoria própria (2023).

Figura 9 – Localização espacial dos dados da série temporal. Os círculos indicam os *pixels* em cada superfície de previsão que contém os dados da série temporal para o ano de 2020



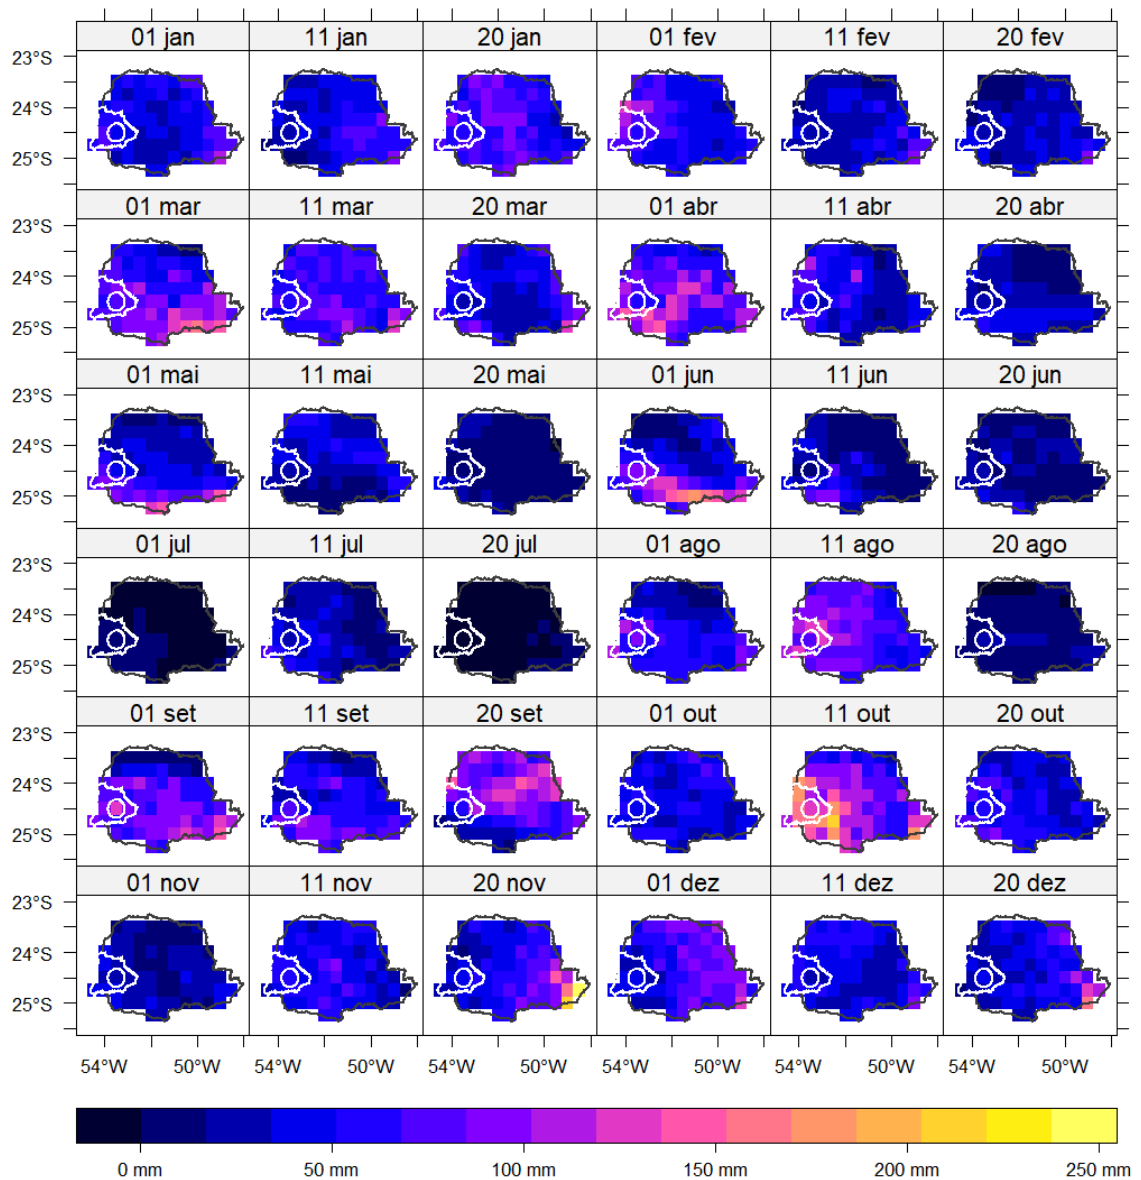
Fonte: Autoria própria (2023).

Figura 10 – Localização espacial dos dados da série temporal. Os círculos indicam os *pixels* em cada superfície de previsão que contém os dados da série temporal para o ano de 2021



Fonte: Autoria própria (2023).

Figura 11 – Localização espacial dos dados da série temporal. Os círculos indicam os *pixels* em cada superfície de previsão que contém os dados da série temporal para o ano de 2022




Fonte: Autoria própria (2023).

Nas Figuras 12 a 16 são apresentadas as séries temporais provenientes dos dados dos *pixels* indicados da Figura 7 a 11. Essas séries consistem de 36 valores, representando três previsões decendiais para cada mês do ano. Observa-se um padrão não estacionário nessas séries de dados de precipitação pluviométrica, um fenômeno comum em séries temporais provenientes de sistemas físicos, caracterizado pela não constância nos momentos estatísticos, como média e variância, ao longo dos segmentos da série (BOLZAN, 2004). Podemos assim analisar as séries de cada ano, descrevendo cada uma da seguinte forma:

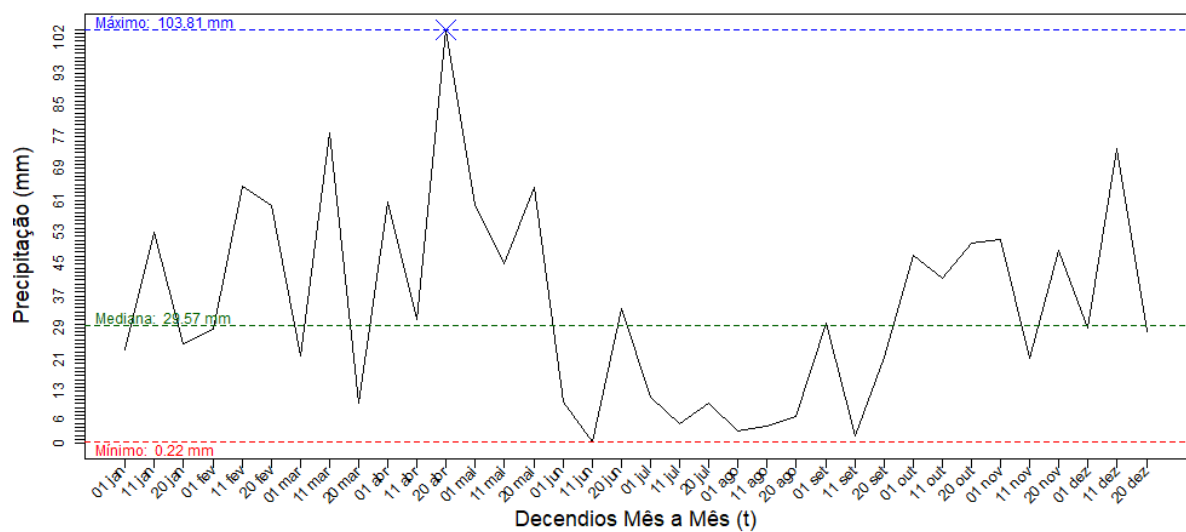
- 2018 teve cinco picos de precipitação acumulada, sendo eles, 11 de Janeiro, 11 de Maio, 01 de Junho, 20 de Setembro e 01 de Outubro. Por outro lado, tivemos períodos de baixo acúmulo de precipitação em 11 de Abril, 20 de Abril, 01 de Maio, 01 de Julho, 11 de Julho, 11 de Agosto e 01 de Dezembro.
- 2019 tem uma boa precipitação acumulada em 11 de Março, 20 de Abril e 11 de Dezembro e períodos de baixa precipitação em 11 de Junho, 01 de Agosto e 11 de Setembro.
- 2020 temos picos de precipitação acumulada em 01 Junho, 11 de Agosto e 01 de Dezembro. Períodos de seca em 20 de Março, 20 de Abril, 11 de Junho, 01 de Agosto, 01 de Outubro e 01 de Novembro.
- 2021 tendo seis períodos de estiagem, sendo eles 01 de Abril, 01 de Maio, 01 de Julho, 01 de Agosto, 01 de Setembro e 20 de Setembro. Porém também temos o período com o decêndio de maior acúmulo de precipitações, 01 de Outubro.
- 2022 pode ser observado um pico no decêndio de 01 Junho, e nos decêndios 01 de Setembro e 11 de Outubro, que representam altas precipitações acumuladas. Também pode ser observado em 01 de Julho e 20 de Julho como sendo os períodos de estiagem.

Figura 12 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2018




Fonte: Autoria própria (2023).

Figura 13 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2019




Fonte: Autoria própria (2023).

Figura 14 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2020



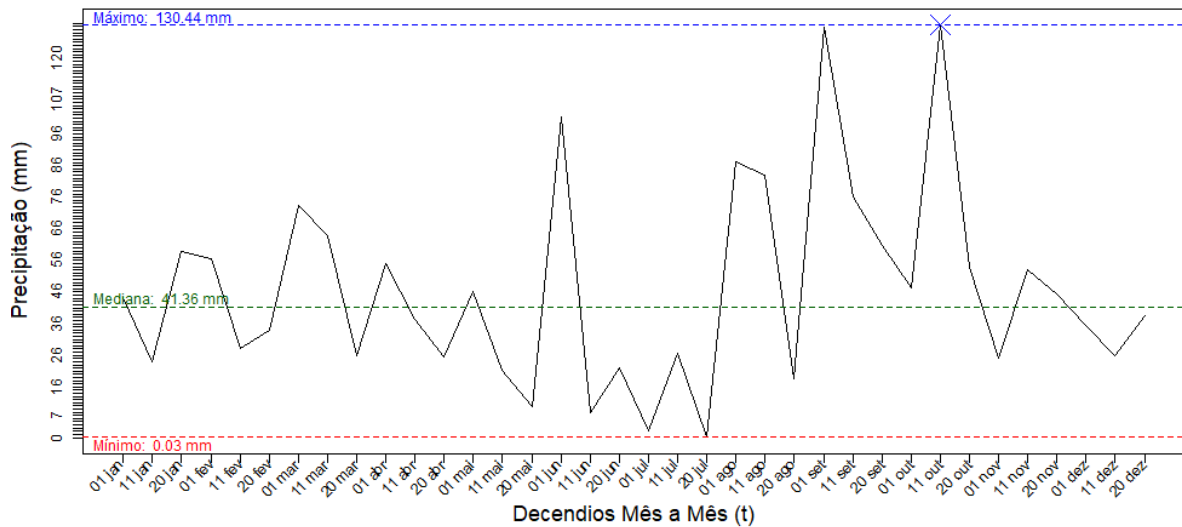
Fonte: Autoria própria (2023).

Figura 15 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2021



Fonte: Autoria própria (2023).

Figura 16 – Série Temporal de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2022




Fonte: Autoria própria (2023).

Os gráficos do espectro de potência de *wavelet*, ilustrados nas Figuras 17 a 21, são uma representação visual que resulta da aplicação da análise de *wavelet* a uma série temporal. Eles fornecem informações sobre a distribuição de energia em diferentes escalas de tempo, ajudando a identificar padrões e variações temporais em dados complexos.

A análise de *wavelet* divide a série temporal em diferentes componentes de frequência e permite analisar como a amplitude dessas frequências varia ao longo do tempo. O gráfico do espectro de potência de *wavelet* representa essa variação de amplitude em um plano bidimensional, onde o eixo horizontal representa o tempo e o eixo vertical representa as diferentes escalas de frequência (ou períodos). A intensidade das cores ou a altura das curvas no gráfico indicam a intensidade da variabilidade em uma determinada escala de tempo. Áreas mais intensamente coloridas ou picos mais altos indicam períodos em que a série temporal exibe maior energia ou variabilidade naquela escala específica (BOLZAN, 2006).


A interpretação destes gráficos (Figuras 17 a 21) envolve a identificação de padrões temporais em diferentes escalas. Por exemplo, picos em escalas mais longas podem representar padrões sazonais, enquanto picos em escalas mais curtas podem indicar variações de curto prazo. A análise desses padrões pode ajudar a entender a dinâmica temporal dos dados e identificar ciclos ou eventos significativos.

Figura 17 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2018, obtidos com a wavelet de Morlet




Fonte: Autoria própria (2023).

Figura 18 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2019, obtidos com a wavelet de Morlet




Fonte: Autoria própria (2023).

Figura 19 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2020, obtidos com a wavelet de Morlet



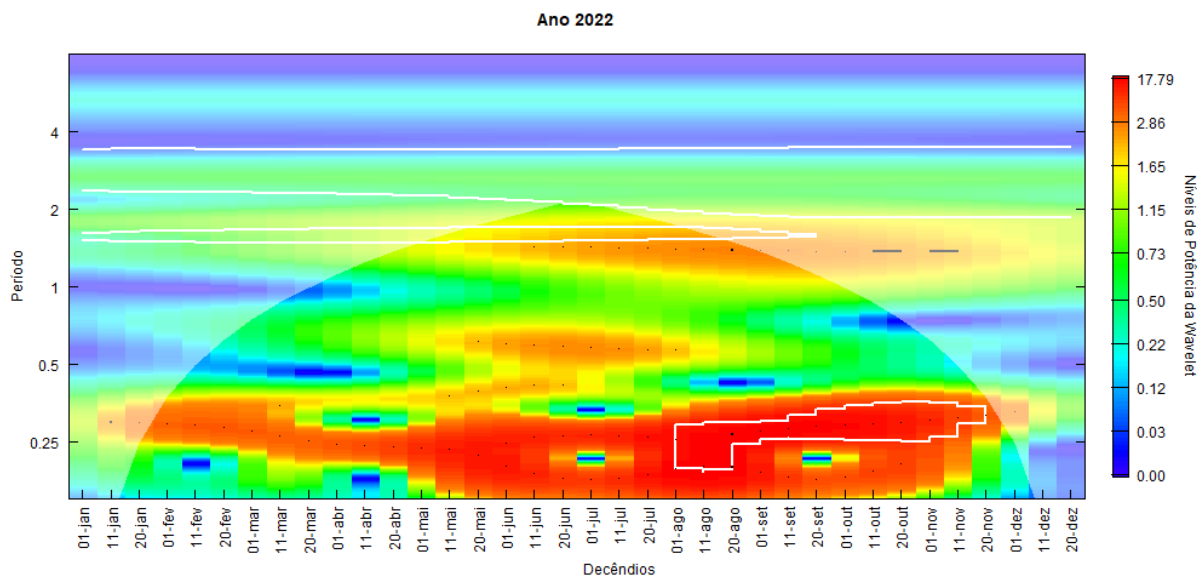
Fonte: Autoria própria (2023).

Figura 20 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (pixel 94) ano 2021, obtidos com a wavelet de Morlet



Fonte: Autoria própria (2023).

Figura 21 – Periodogramas das séries temporais de previsão de precipitação decendial para Toledo e Cascavel - PR (*pixel* 94) ano 2022, obtidos com a *wavelet* de Morlet



Fonte: Autoria própria (2023).

Ao avaliar os gráficos nas Figuras 18 a 21, identifica-se o cone de influência, que sinaliza a área de confiabilidade dos dados — elementos fora dessa zona, representados pela parte clareada, são omitidos na interpretação. Observa-se ainda que os períodos de maior intensidade, destacados em vermelho, mudaram de posição durante os cinco anos analisados, migrando do início para o meio e, em seguida, do meio para o final dos anos, indicando as épocas de previsões de chuvas mais intensas na área estudada. Além disso, contornos definidos por linhas brancas demarcam as regiões em que os valores de potência da transformada de wavelet são estatisticamente significativos, como descrito na documentação da biblioteca *WaveletComp* por Roesch e Schmidbauer (2018), usada para gerar os periodogramas.

A Tabela 1 fornece uma visão organizada dos resultados da análise do espectro de potência de wavelet ao longo de vários anos, destacando os períodos de significância estatística associadas a um determinado *pixel*. As células da tabela contêm informações detalhadas sobre os períodos de interesse. Por exemplo, na célula correspondente a 2018 e “Nível de Significância”, três períodos diferentes são listados, indicando que nesses momentos o espectro de potência foi estatisticamente significativo, onde as previsões indicam precipitações mais atuantes na região de estudo.

Como resultado desse trabalho, obteve-se uma melhor compreensão dos dados meteorológicos relacionados à previsão de precipitação pluviométrica, considerados para a região específica (Seção 3.1.2) em termos de suas características geoespaciais e temporais. Para isso, dominou-se suficientemente a linguagem de programação (Seção 3.1.5) e as bibliotecas usadas para o tratamento desses dados, assim como se compreendeu o formato utilizado pelo ECMWF (Seção 3.1.1) na disponibilização dos dados meteorológicos. Também, pode-se obter

uma melhor compreensão dos gráficos do espectro de potência de *wavelet*, que por sua vez fornecem informações importantes para a análise de séries temporais não-estacionárias.

Tabela 1 – Tabela demonstrativa dos dados encontrados nas Figuras 17 a 21

Ano	Períodos com Nível de Significância
2018	11 de fevereiro a 01 de Junho
	20 de Abril a 01 de Maio
	01 de Outubro a 20 de Novembro
2019	01 de Março a 01 de Maio
2020	01 de Julho a 11 de Agosto
	01 a 11 de Agosto
2021	11 de Setembro a 11 de Novembro
2022	01 de Agosto a 20 de Novembro

Fonte: Autoria própria (2023).

5 CONCLUSÃO

A investigação de séries temporais derivadas de modelos preditivos é vital em vários campos científicos, tais como estatística, meteorologia, agricultura, economia e ciência de dados. Quando essa análise é conjugada com dados espaciais, ela fornece perspectivas valiosas acerca da distribuição espacial dos fenômenos, contribuindo para o reconhecimento de padrões geográficos e para a compreensão das interações entre as variáveis ao longo do tempo e do espaço. A transformada de *wavelet* emerge como um instrumento matemático fundamental nessa integração, pois permite a decomposição de informações em diversas escalas e frequências, desvendando assim, padrões e tendências que não são imediatamente aparentes.

Este estudo apresentou uma análise de séries temporais não estacionárias de previsão de chuvas, aplicando a transformada *wavelet* conforme proposto por Morlet *et al.* (1982) (Capítulo 3, Seção 2.2). As séries foram obtidas através do modelo TIGGE, que fornece previsões decendiais (de 10 dias) e estão acessíveis na plataforma do Centro Europeu de Previsões Meteorológicas a Médio Prazo, via um *script* em Python detalhado na Listagem 1 (Seção 3.1.4). Os dados, uma vez extraídos pelo método previamente descrito, foram processados utilizando-se *scripts* elaborados na linguagem R (Seção 3.1.5) e disponíveis integralmente através do endereço <https://github.com/andrelquiosi/WaveletsTimeSeries>, com o intuito de serem exibidos em tabelas, gráficos e figuras no Capítulo 4. As visualizações gráficas fornecidas propiciaram uma compreensão aprofundada do comportamento das séries temporais, permitindo derivar conclusões substantivas a partir das evidências apresentadas. Os gráficos, em particular, com suas escalas meticulosas e detalhamento minucioso, contribuem significativamente para a identificação de alterações e padrões emergentes.

A complexidade do processamento dos dados varia com o volume a ser analisado, podendo resultar em um processo oneroso em termos de manipulação, processamento e apresentação dos mesmos. Observou-se, através da revisão de estudos correlatos, que a aplicação da transformada *wavelet* está se expandindo intensamente, tanto no Brasil quanto internacionalmente, com usos diversificados, sendo notavelmente prevalente no tratamento de dados meteorológicos.

Para este estudo, delimitou-se a análise a dados de previsão de precipitação cobrindo um período de cinco anos. No entanto, destaca-se a possibilidade de extensão da análise para abranger um leque mais amplo de variáveis meteorológicas, disponíveis em bases de dados renomadas como a do ECMWF. A inclusão de variáveis inter-relacionadas pode potencializar a análise, proporcionando uma visão mais detalhada e conclusões mais robustas acerca dos fenômenos climáticos estudados.

REFERÊNCIAS

- ALMEIDA, E. C. S. d. **Agroindústrias: a indústria motriz que desenvolve a região Oeste do Paraná**. 2020. Dissertação (Mestrado), 2020.
- BOLZAN, M. J. A. Análise da transformada em ondeletas aplicada em sinal geofísico. **Revista Brasileira de Ensino de Física**, SciELO Brasil, v. 26, p. 37–41, 2004.
- BOLZAN, M. J. A. Transformada em ondeleta: Uma necessidade. **Revista Brasileira de Ensino de Física**, SciELO Brasil, v. 28, p. 563–567, 2006.
- CHIDEPUDI, S. K. R. *et al.* A wavelet-assisted deep learning approach for simulating groundwater levels affected by low-frequency variability. **Science of The Total Environment**, Elsevier, v. 865, p. 161035, 2023.
- KISI, O.; CIMEN, M. Precipitation forecasting by using wavelet-support vector machine conjunction model. **Engineering Applications of Artificial Intelligence**, Elsevier, v. 25, n. 4, p. 783–792, 2012.
- LEPIK, Ü.; HEIN, H. Haar wavelets. *In: Haar Wavelets: With Applications*. [S.l.]: Springer, 2014. p. 7–20.
- LINA, J.-M.; MAYRAND, M. Complex daubechies wavelets. **Applied and Computational Harmonic Analysis**, Elsevier, v. 2, n. 3, p. 219–229, 1995.
- LOPES, G. R.; DELBEM, A. C.; SOUSA, J. B. de. Introdução à análise de dados geoespaciais com python. **Sociedade Brasileira de Computação**, 2021.
- MALHI, G. S.; KAUR, M.; KAUSHIK, P. Impact of climate change on agriculture and its mitigation strategies: A review. **Sustainability**, MDPI, v. 13, n. 3, p. 1318, 2021.
- MORETTIN, P. A.; TOLOI, C. M. **Análise de séries temporais: modelos lineares univariados**. [S.l.]: Editora Blucher, 2018.
- MORLET, J. *et al.* Wave propagation and sampling theory; Part I, Complex signal and scattering in multilayered media. **Geophysics**, v. 47, n. 2, p. 203–221, 02 1982. ISSN 0016-8033. Disponível em: <https://doi.org/10.1190/1.1441328>.
- NORDEMANN, D. J. R. Periodicidades, tendências e previsão a partir da análise espectral dinâmica da série dos níveis do rio paraguaí, em ladário (1900/1995). **Pesquisa Agropecuária Brasileira**, v. 33, n. 13, p. 1787–1790, 1998.
- ROESCH, A.; SCHMIDBAUER, H. **WaveletComp: Computational Wavelet Analysis**. [S.l.], 2018. R package version 1.1. Disponível em: <https://CRAN.R-project.org/package=WaveletComp>.
- SANTOS, C.; FREIRE, P. Analysis of precipitation time series of urban centers of northeastern brazil using wavelet. **Int J Environ Ecol Geol Geophys Eng**, v. 6, n. 7, p. 64–69, 2012.
- SANTOS, C. A. G.; MORAIS, B. S. de. Identification of precipitation zones within são francisco river basin (brazil) by global wavelet power spectra. **Hydrological sciences journal**, Taylor & Francis, v. 58, n. 4, p. 789–796, 2013.
- VETTERLI, M.; HERLEY, C. Wavelets and filter banks: Theory and design. **IEEE transactions on signal processing**, v. 40, n. ARTICLE, p. 2207–2232, 1992.

WEI, D. **Coiflet-type wavelets: theory, design, and applications**. [S.l.]: The University of Texas at Austin, 1998.

WU, X. *et al.* The development of a hybrid wavelet-arima-lstm model for precipitation amounts and drought analysis. **Atmosphere**, MDPI, v. 12, n. 1, p. 74, 2021.

YEDITHA, P. K. *et al.* Development of monthly scale precipitation forecasting model for indian subcontinent using wavelet based deep learning approach. Preprints, 2023.